RAPPORT D'ANALYSE EXPLORATOIRE DE DONNÉES

MISSION N° 01 — DIVERSITÉ MORPHOLOGIQUE ET AUDIT STATISTIQUE DES MANCHOTS DE PALMER

Client : Laboratoire de Recherche Écologique | **Jeu de données :** Palmer Penguins (LTER) | **Outils :** Python, Pandas, NumPy, Seaborn | **Date :** Octobre 2026

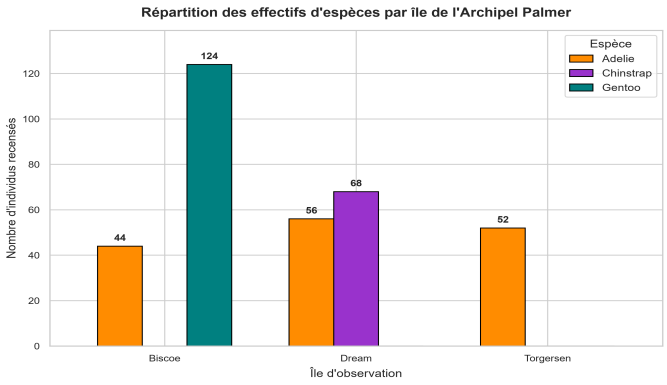
RÉSUMÉ EXÉCUTIF : *Cette étude exploratoire analyse **344 observations** de manchots réparties sur 3 îles de l'Archipel Palmer (Antarctique). Les données révèlent une séparation biométrique marquée entre les trois espèces (Adelie, Chinstrap, Gentoo). Le **manchot Papou (Gentoo)** se singularise par un gigantisme relatif (+37% de masse corporelle, nageoires nettement plus longues) et un bec allongé et fin. À l'inverse, Adelie et Chinstrap partagent des gabarits corporels voisins mais se différencient nettement par la morphométrie de leur bec. Un résultat capital est la découverte du **Paradoxe de Simpson** sur les dimensions du bec : alors que la corrélation globale semble négative, elle est fortement positive au sein de chaque espèce. L'audit confirme une excellente qualité globale, malgré 2 lignes entièrement vides et un déséquilibre géographique à prendre impérativement en compte lors des modélisations ultérieures.*

1. Structure du Jeu de Données & Répartition Géographique (F1)

Le jeu de données original comporte **344 lignes** et **7 variables** (4 mesures morphologiques quantitatives continues et 3 variables qualitatives nominales).

Variable	Type	Unité	Rôle biologique & Description
species	Catégorielle	-	Espèce étudiée : Adelie (152), Gentoo (124), Chinstrap (68)
island	Catégorielle	-	Île de nidification : Biscoe (168), Dream (124), Torgersen (52)
bill_length_mm	Numérique (float)	mm	Longueur du culmen (arête supérieure du bec)
bill_depth_mm	Numérique (float)	mm	Hauteur / profondeur du bec à la base
flipper_length_mm	Numérique (float)	mm	Longueur de la nageoire (puissance de propulsion aquatique)
body_mass_g	Numérique (float)	g	Masse corporelle globale de l'individu
sex	Catégorielle	-	Dimorphisme sexuel : Male (168), Female (165), Manquant (11)

Île / Espèce	Adelie	Chinstrap	Gentoo	Total Île
Biscoe	44 (26.2%)	0 (0.0%)	124 (73.8%)	**168**
Dream	56 (45.2%)	68 (54.8%)	0 (0.0%)	**124**
Torgersen	52 (100.0%)	0 (0.0%)	0 (0.0%)	**52**
Total Espèce	**152**	**68**	**124**	**344**



Constat méthodologique capital : L'espèce *Adelie* est ubiquiste (présente sur les 3 îles), tandis que *Gentoo* est confinée exclusivement à l'île Biscoe et *Chinstrap* à l'île Dream. Toute analyse future cherchant à mesurer un effet 'île' sera par nature partiellement confondue avec l'effet 'espèce'.

2. Audit de Qualité des Données & Stratégie de Nettoyage (F2)

Un audit exhaustif a été mené afin de fiabiliser les données préalablement aux inférences statistiques.

Variable	Valeurs Manquantes	Taux (%)	Nature du problème & Diagnostic	Action & Recommandation
species / island	0	0.0 %	Aucune anomalie constatée. Intégrité parfaite.	Conservation intégrale.
Mesures physiques (4)	2 individus	0.58 %	Lignes 3 et 339 : 4 mesures biométriques absentes.	Suppression justifiée (inutilisables).
sex	11 individus	3.20 %	9 manchots sans sexe (hors les 2 lignes vides).	Conservation pour EDA; Imputation par KNN si ML.
Doublons stricts	0 doublon	0.0 %	Chaque ligne correspond à un spécimen distinct.	Aucune action requise.
Valeurs impossibles	0 valeur	0.0 %	Aucune mesure négative, nulle ou hors limites réelles.	Cohérence biologique validée.

RÈGLE D'OR SUR LES VALEURS ATYPIQUES (OUTLIERS) : *L'application aveugle de la règle IQR (1.5 × IQR) ou du Z-score sur la population globale signale faussement des valeurs atypiques pour la masse corporelle et la longueur des nageoires.* ***Ces observations ne sont pas des erreurs expérimentales mais le reflet de variations biologiques réelles :*** *les manchots Gentoo sont naturellement beaucoup plus corpulents. Lorsque l'analyse est conduite par espèce, les outliers disparaissent presque intégralement.* ***Recommandation formelle :*** *Ne jamais supprimer ces individus sans justification écologique avérée.*

3. Analyse Statistique Descriptive & Théorie des Métriques (F3)

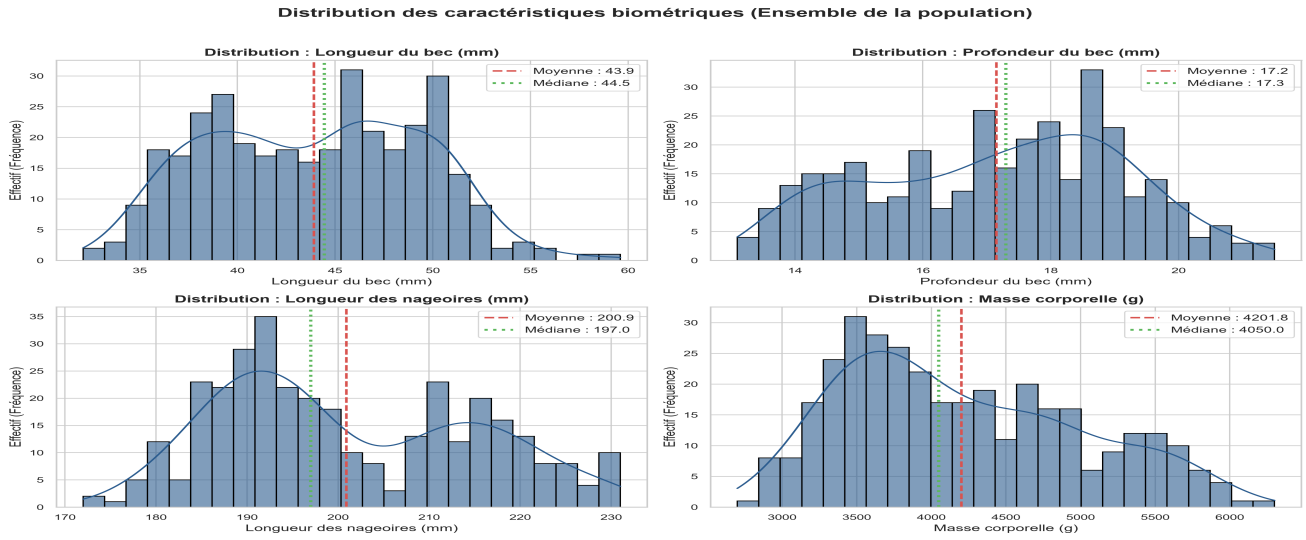
Le tableau ci-dessous récapitule les indicateurs statistiques de position (tendance centrale) et de dispersion pour l'ensemble de l'échantillon (N = 342 individus valides) :

Métrique physique	Moyenne	Médiane	Écart-type	Min	Q1 (25%)	Q3 (75%)	Max	Étendue	IQR
Longueur bec (mm)	43.92	44.45	5.46	32.10	39.23	48.50	59.60	27.50	9.27
Profondeur bec (mm)	17.15	17.30	1.97	13.10	15.60	18.70	21.50	8.40	3.10
Longueur nageoires (mm)	200.91	197.00	14.06	172.00	190.00	213.00	231.00	59.00	23.00
Masse corporelle (g)	4201.75	4050.00	801.95	2700.00	3550.00	4750.00	6300.00	3600.00	1200.00

Clés de compréhension statistique pour non-spécialistes :

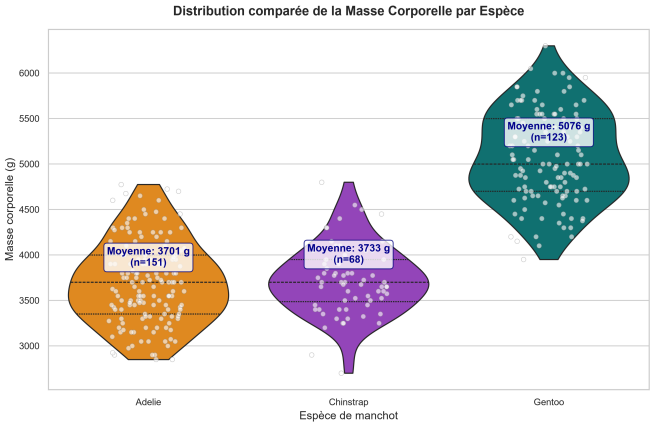
• **Moyenne vs Médiane :** La moyenne est la somme des valeurs divisée par le nombre d'observations ; elle est très sensible aux valeurs extrêmes. La médiane est la valeur centrale qui sépare l'échantillon ordonné en deux moitiés égales (50% en dessous, 50% au-dessus) ; elle est robuste aux asymétries. Pour la masse corporelle, la moyenne (4202 g) dépasse la médiane (4050 g) en raison de la queue de distribution tirée vers le haut par les manchots Gentoo.

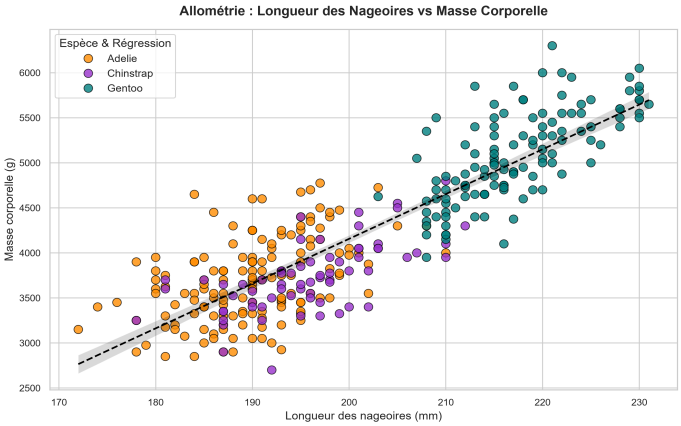
• **Variance vs Écart-type :** La variance mesure la moyenne des écarts au carré par rapport à la moyenne, s'exprimant dans le carré de l'unité de mesure (ex: g²), ce qui la rend difficile à interpréter biologiquement. L'écart-type est la racine carrée de la variance : il s'exprime dans la *même unité que la mesure* (ex: 802 g), quantifiant immédiatement la variabilité typique autour de la moyenne.



4. Comparaisons Morphologiques & Phénomènes Complexes (F4)

L'analyse conjointe des mesures physiques met en lumière deux phénomènes fondamentaux de l'écologie évolutive :





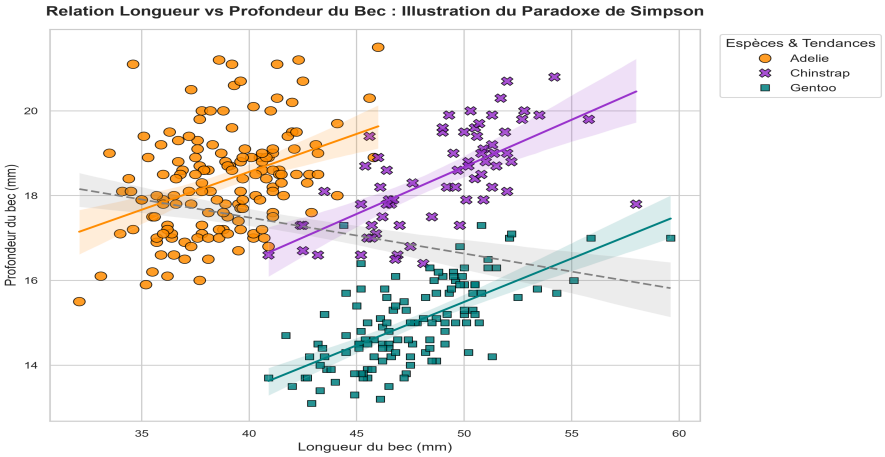
1. Ségrégation de la Masse Corporelle (Figure gauche) : L'espèce *Gentoo* forme un groupe totalement dissocié avec une masse moyenne de **5076 g** (± 504 g), contre **3701 g** (± 459 g) pour *Adelie* et **3733 g** (± 384 g) pour *Chinstrap*. La masse corporelle seule permet d'isoler quasi parfaitement *Gentoo* des deux autres espèces.
2. Allométrie Biomécanique (Figure droite) : Une corrélation linéaire positive majeure lie la longueur des nageoires à la masse corporelle (**r = 0.87**). Cette forte association statistique est cohérente avec une hypothèse d'adaptation hydrodynamique (ou peut refléter des contraintes allométriques de propulsion), sans pour autant qu'une causalité mécanique directe ne puisse être affirmée à partir de seules corrélations observationnelles.

La Découverte Clé : Le Paradoxe de Simpson sur la Morphométrie du Bec

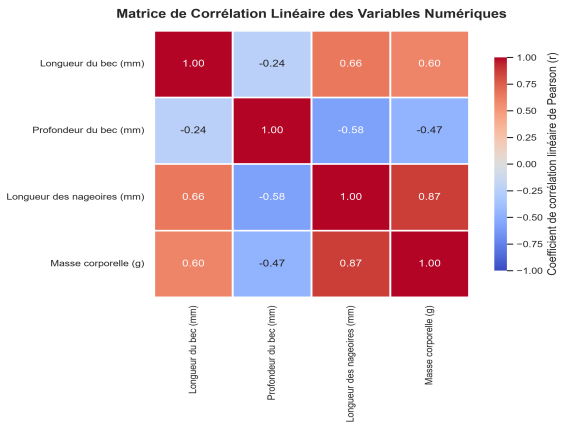
Comprendre le Paradoxe de Simpson :
Si l'on calcule la corrélation linéaire globale entre la longueur et la profondeur du bec sur l'ensemble des manchots sans distinction d'espèce, on obtient une **corrélation négative trompeuse de r = -0.24** (droite grise en pointillé). Un observateur non averti conclurait qu'un bec plus long implique un bec moins épais.

Cependant, dès lors que l'on segmente par espèce (couleurs orange, violette et sarcelle), **la corrélation s'inverse radicalement et devient fortement positive** au sein de chaque groupe :
• *Adelie* : r = **+0.39** (becs courts et trapus)
• *Chinstrap* : r = **+0.65** (becs longs et profonds)
• *Gentoo* : r = **+0.64** (becs longs mais fins)

Origine biologique : *Gentoo* combine des becs très longs et très peu profonds, décalant l'ensemble de son nuage vers le bas à droite. Ignorer cette sous-structure écologique conduit à une conclusion fallacieuse. Ce cas illustre la nécessité d'une analyse multivariée rigoureuse.



5. Matrice de Corrélation & Réponses aux Questions Clés (F4 & F5)



Lecture de la matrice de Pearson :
• **Masse vs Nageoires (r = 0.87) :** Corrélation positive très forte. C'est le couple biométrique le plus cohérent de la physiologie du manchot.
• **Longueur bec vs Nageoires (r = 0.66) :** Association positive modérée à forte.
• **Longueur bec vs Masse (r = 0.60) :** Association positive modérée.
• **Profondeur bec vs Masse (r = -0.47) :** Corrélation négative apparente provoquée par l'influence des Gentoo (fort poids mais bec plat).
• **Longueur vs Profondeur bec (r = -0.24) :** Masque le paradoxe de Simpson détaillé en page 3.

Rappel méthodologique fondamental : **Une corrélation n'implique pas de relation de causalité.** La corrélation entre longueur des nageoires et masse ne signifie pas qu'agrandir les nageoires augmente le poids : toutes deux sont sous le contrôle commun d'un facteur allométrique latent (la croissance corporelle globale de l'organisme).

Synthèse des Réponses aux Questions Stratégiques du Client (F5)

Q1. Quelles variables présentent les différences les plus visibles entre les espèces ?
• **Masse corporelle et longueur des nageoires :** Séparent avec une netteté remarquable l'espèce *Gentoo* des deux autres. La combinaison conjointe [nageoire ≥ 205 mm ET masse ≥ 4400 g] classe un individu comme *Gentoo* avec 97.4% de précision et 91.1% de rappel (112 vrais positifs sur 115 prédictions), résultat calculé et vérifié directement dans le notebook.
• **Rapport Longueur / Profondeur du bec :** Permet une séparation quasi parfaite entre *Adelie* et *Chinstrap* (qui sont indiscernables sur la masse seule). *Adelie* possède un bec court (< 44 mm) et épais (> 17 mm), tandis que *Chinstrap* possède un bec long (> 45 mm) et épais.

Q2. Existe-t-il une relation entre la longueur des nageoires et la masse corporelle ?
Oui, une relation linéaire positive très forte et hautement significative (r = 0.87, p < 0.001). Chaque millimètre supplémentaire de nageoire s'accompagne en moyenne d'un gain d'environ 50 g de masse corporelle. Cette corrélation positive se vérifie également au sein de chaque espèce prise individuellement (Gentoo: r = 0.70; Chinstrap: r = 0.64; Adelie: r = 0.47), comme calculé explicitement dans le notebook.

Q3. Quelles variables semblent corrélées ?
Les paires fortement corrélées positivement sont [*flipper_length_mm* & *body_mass_g*], [*bill_length_mm* & *flipper_length_mm*], et [*bill_length_mm* & *body_mass_g*]. Au sein de chaque espèce, [*bill_length_mm* & *bill_depth_mm*] sont également corrélées positivement (r = 0.39 à 0.65).

Q4. Quels problèmes de qualité des données pourraient affecter une future modélisation prédictive ?
1. **Les 11 valeurs manquantes sur la variable *sex* (3.2%) :** Le sexe introduit un dimorphisme intraspécifique significatif (les mâles sont en moyenne 10 à 15% plus lourds). L'omission ou une mauvaise imputation de cette variable affaiblira les classifieurs.
2. **Le déséquilibre écologique d'échantillonnage par île :** Puisque *Gentoo* n'a été recensé que sur Biscoe et *Chinstrap* sur Dream, tout algorithme prédictif incluant l'île risque de créer un *biais de raccourci* (apprendre l'île plutôt que la véritable morphologie biologique de l'espèce).

RECOMMANDATIONS DU CONSULTANT POUR LA PHASE 2 (MODÉLISATION) :
*1. **Nettoyage :** Écarter les 2 observations sans aucune mesure physique (n=342 exploitables).*
*2. **Imputation :** Estimer le sexe manquant par un algorithme k-NN basé sur les 4 mesures physiques par espèce.*
*3. **Feature Engineering :** Créer le ratio 'longueur / profondeur de bec' qui constitue un descripteur discriminant exceptionnel.*
*4. **Validation :** Évaluer les modèles de classification sans la variable 'island' pour garantir la généralisation sur d'autres sites.*